

视觉语言相册检索项目个人技术总结

张添翼

学号：U202315231

2026 年 8 月

摘要

本报告总结我在视觉语言相册检索课程项目中的个人工作。项目的开发起点是队友已经提交的 M3-M5 多路索引、检索服务与 RRF 融合基线；我没有把这些已有代码记为个人独立成果，而是在其上继续扩展无标注开发流程、M5 融合对照、M6 视觉重排、M7 故事与缺图补全、M4 查询理解后端以及 A7 图像编码器适配。全部本地联调在 RTX 4060 Laptop 8GB 环境下开展，重点考察功能契约、异常降级、显存与时延。现阶段的 20/64 图实验只能支持工程和资源可行性结论；全量结构化标注、人工相关性判断（relevance judgments）及正式 A5-A7 质量实验仍是团队共同依赖，本文不据小样声明 Recall、MRR、mAP 或 nDCG 提升。

关键词：视觉语言模型；多模态检索；重排序；视觉故事；本地部署

贡献归属声明： Git 提交 222f232 中原始 M3-M5 多模态检索流水线归属队友。本报告所称“本人工作”仅指从 4457459 起对该基线所做的扩展、补全、联调、验证与修复。

1 项目背景与个人任务边界

项目目标是让用户用中文自然语言检索个人相册，并在召回结果上完成引用问答和图文故事。技术计划将主链路划分为：M3 建立图像、结构化文本和 BM25 索引；M4 将查询拆成语义文本与硬条件；M5 融合三路召回；M6 用视觉语言模型重排 Top-20；M7 输出带引用回答、排序故事及带“AI 生成”标识的补图。图像塔采用 Chinese-CLIP 或 jina-clip-v2，二者均把文本与图片映射到同一向量空间 [5, 8]；向量索引由 FAISS 支持 [6]。

系统中的模型承担不同职责。Chinese-CLIP 是默认的快速广召回编码器：它预先编码图片，查询时只需编码文本并做向量近邻搜索。Qwen3-VL-2B-Instruct 则是较慢但能生成文本的图像理解模型，用于候选重排、带引用问答、故事和文生图提示词 [7]。因此 CLIP 解决“从大量图片中快速找候选”，Qwen3-VL 解决“对少量候选进行深入理解”。

2 队友代码基线分析

队友在提交 222f232 中已经形成 M3-M5 基线：图片向量、结构化描述向量与关键词 BM25 三路索引分别返回候选，搜索服务再用 RRF 按名次合并结果。RRF 不要求三路原始分数处在同一尺度，适合异构召回 [2]。该结构提供了清楚的编码器、索引、融合与服务边界，使后续功能可以逐层替换并保留默认行为。我的工作以此为起点，重点补足无标注阶段的可运行入口、替代算法对照、生成式模型联调、异常防护和可复现实验，而不是重新声明已有流水线的所有权。

表 1: 模块、开发起点与个人任务边界

模块	队友已有/共同起点	本人扩展	当前结论边界
M3	队友已有三路索引框架	补全 image-only、任意目录和编码器切换	全量索引待标注冻结
M4	检索服务接口	补全规则、本地 Qwen、兼容 API 三后端	三查询只验证接口契约
M5	队友已有 RRF 基线	加入归一化加权融合和对照脚本	无人工相关性，不判质量优劣
M6	候选重排接口	补全 Top-20 listwise、校验和降级	小样只支持资源结论
M7	检索结果与 UI 起点	扩展自动故事、缺图补全和 AI 标识	故事质量待人工评分
A7	Chinese-CLIP 默认图像塔	适配 jina-clip-v2 并修复 NaN	64 图只做资源对比

3 个人技术工作

3.1 无标注开发模式与任意目录流水线

问题：队友仍在生成 M1 结构化标注时，完整文本索引与正式评测不能启动；若所有开发都等待交付，接口和显存问题会集中到最后阶段。**本人工作：**我补全 mock、image-only、full 三种运行模式，并增加任意图片目录的一键清单生成、配置复制、图像建库和服务入口。没有标注时只运行图像检索，不伪造结构化字段；收到标注后可切换 full 模式。**验证：**隐藏目录与 image-only 流程经过自动化测试，阶段产物均放在 Git 忽略目录。**限制：**mock 只验证接口，image-only 只验证图像分支，两者均不能替代完整 M3 或检索质量实验。

3.2 M5：归一化加权融合对照

问题：原有 RRF 能规避分数量纲差异，但技术计划同时要求与归一化加权和对照。**本人工作：**我在不改变默认 RRF 的前提下，增加分支内 min-max 归一化和可配置权重；分支不可用时只在有效分支间重新归一化权重，并保留每路原始分数、名次和降级信息。**验证：**在 20 图、17 条有效结构化标注和 12 条查询上，两种融合均完成 Top-8 检索，候选重合率和位次变化可被脚本复现。**限制：**该对照没有人工 qrels，92.71% 重合率只描述两个算法输出的相似程度，不代表准确率。

3.3 M6：Top-20 Listwise 视觉重排

问题：逐图 pointwise 调用稳定，但 Top-20 需要 20 次模型推理；listwise 一次处理候选更快，却可能输出未知、重复或遗漏 ID。多模态大模型作为重排器已有相关探索 [3]。**本人工作：**我把候选缩放为 5 列 contact sheet，保留编号和 image ID，并实现输出白名单、编号映射、去重、遗漏项按原序补尾以及硬失败/部分降级分开计数。**验证：**3 条 Top-20 查询在 8GB 显存上运行完成，listwise 将每查询模型调用从 20 次降为 1 次。**限制：**其中 1/3 查询出现部分降级；没有人工 relevance，不能说明 listwise 排序质量优于 pointwise。

3.4 M7: 自动故事与缺图补全

问题: 技术计划要求把 3–8 张图片组织为故事, 并对叙事缺口生成插图; 生成内容必须与实拍图明确区分。视觉故事任务可参考 VIST 的图像序列叙事设定 [4]。**本人工作:** 我扩展了按时间桶和场景相似度排序、跨时段/低相似跳变检测、Qwen 故事与提示词生成、Stable Diffusion 1.5 FP16 补图, 以及 `source=generated`、`ai_generated=true` 双重标识。进入扩散模型前卸载 Qwen, 生成失败时保留原故事并显示原因。交互页面基于 Gradio[1]。**验证:** 本地 Qwen 故事链和 512×512 PNG 补图均真实运行, 生成记录含固定 seed 和 AI 标识。**限制:** SD 1.5 是适合本机联调的阶段模型, 并非计划首选的 SDXL/FLUX; 现有结果不代表故事连贯性或风格一致性得分。

3.5 M4: 三后端查询理解

问题: 否定、数量和 OCR 查询不能只依赖向量相似度; 同时, 本地模型或免费 API 不可用时不能阻断检索。**本人工作:** 我补全 rules、local Qwen 和 OpenAI-compatible 三后端。规则层先保护场景、时间、数量、OCR 和否定等硬条件; LLM 仅补充软字段与 `semantic_text`, 失败则记录原因并回退规则。兼容 API 客户端实现环境变量取 Key、超时、重试和响应解析。**验证:** 本地 Qwen 的否定、数量、OCR 三类查询均完成结构化输出; 无 Key 时 API 后端明确记录错误并安全回退。**限制:** 尚无外部服务 Key, 故只完成协议测试而未声称真实免费 API 调用成功; 3/3 也不是查询理解准确率。

3.6 A7: jina-clip-v2 适配与稳定性修复

问题: A7 要求对比两个图像编码器, 但 jina-clip-v2 初次加载后图像向量全为 NaN, 不能直接写入 FAISS。**本人工作:** 我增加编码器配置切换、Matryoshka 维度截断与索引元数据, 并用逐层钩子定位 NaN 首次出现于视觉塔第 0 层 RoPE。其非持久 `freqs_cos/freqs_sin` 未从 checkpoint 恢复, 我按模型配置确定性重建 buffer, 同时在输出端加入 NaN/Inf 硬校验。**验证:** 修复后的 8 图冒烟和 64 图资源测试均产生有限向量与非空 Top-5, 完整仓库在 A7 提交时为 122 passed。**限制:** 两模型分数不在同一标尺; 资源差异不能推出检索质量差异。

4 本地实验与结果

所有数据均来自 RTX 4060 Laptop 8GB 本地阶段实验。表中“峰值显存”指 PyTorch 的 CUDA 最大分配量, 而非整机 `nvidia-smi` 占用。

表 2: M6 在 3 条查询、每条 Top-20 上的热态资源对照

指标	Pointwise	Listwise
模型调用数	60	3
平均每查询延迟 (s)	44.377	9.143
峰值 CUDA 显存 (GiB)	4.039	4.092
硬失败率	0%	0%
部分降级	不适用	1/3

M6 数据说明 contact-sheet 方案能在 8GB 上运行，并减少本地调用次数与这组测试的耗时；它没有证明排序更相关。M4 中本地 Qwen 完成 3/3 条接口联调：首条冷启动 10.085 s，后两条热调用均值约 2.697 s。M5 小样共 12 查询，RRF 与 weighted 的平均 Top-8 重合率为 92.71%，共同结果平均位次变化 0.446；单次平均延迟分别为 10.58 ms 与 6.62 ms。样本和计时轮数有限，不能据此断言 weighted 总是更快。

表 3: A7 在相同 64 张图片、512 维设置下的资源对照

指标	Chinese-CLIP	jina-clip-v2
冷启动建库 (s)	6.060	10.510
峰值 CUDA 显存 (GiB)	0.394	2.577
平均热查询 (ms)	2.251	47.701
输出维度	512	512

在本次 batch 设置下，Chinese-CLIP 的建库、显存与查询资源开销较低，因此继续作为默认快速召回编码器；jina-clip-v2 保留为多语言和可截断表示的 A7 对照。此结论仅针对资源，正式选择仍需在同一人工 qrels 上比较 Recall@K、MRR、mAP 与 nDCG@10。M7 的 Qwen3-VL-2B 故事链及 SD 1.5 FP16 缺图生成也在本机串行运行，证明链路可执行，未给出故事质量分数。

5 关键问题、修复与反思

1. **结构化输出不等于结构可靠**。Qwen 曾把数组输出成字符串，还把 prompt 示例中的否定词写入查询。修复不是继续堆示例，而是在入口做类型归一化、收紧 schema，并让硬过滤只信任确定性规则。由此我认识到 LLM 输出必须被当作不可信外部输入。
2. **部分结果也要可审计**。Listwise 曾重复 2 个 ID、遗漏 3 个 ID。系统去重并补尾可以保持页面可用，但必须标记 degraded=true，否则会掩盖模型失约。
3. **数值正常性应在索引前阻断**。Jina 的 NaN 并非模型权重损坏，而是低内存加载下非持久 EVA RoPE buffer 未初始化。逐层定位、确定性重建和输出端有限值校验共同构成修复；只在最终检索结果上观察会更难定位。
4. **8GB 的关键是生命周期而非单个峰值**。我采用小 batch、缩略 contact sheet、FP16、attention/VAE slicing，并按“检索编码器 → Qwen → Stable Diffusion”串行卸载加载，避免多个模型同时常驻。该策略以时延换取本机可运行性。

这些问题也说明，自动化测试通过与正式实验完成是两件事：A7 提交时 122 项测试通过，证明接口和回归状态，却不能替代数据覆盖、人工相关性和统计显著性。

6 标注到达后的联调与实验计划

后续按依赖顺序执行，避免在数据尚未冻结时反复调参：

1. **M1 交付验收**：校验文件数量、image ID 唯一性、schema、必填字段、JSON 可解析性、图片路径映射和失败清单；抽样检查 OCR、计数、否定所需字段。

2. **200 图集成**: 先在固定子集运行 full 三路建库和 M4–M7 端到端流程, 记录丢失标注、空字段、索引维度和回退率, 确认无系统性错误后再扩容。
3. **全量索引**: 冻结配置与模型指纹, 分别构建图像、结构化文本和 BM25 索引, 保存耗时、峰值内存、失败样本及可复现命令。
4. **人工 qrels 验收**: 团队共同审核 query、相关等级与数据切分, 避免由系统自身标注生成查询造成循环论证; 检查评分者一致性和困难查询覆盖。
5. **A5–A7 正式实验**: 在相同候选池比较单路/RRF/weighted、无重排/ pointwise/listwise、Chinese-CLIP/jina-clip-v2, 报告分类指标、延迟和失败率。
6. **分析与报告冻结**: 复查失败案例、M7 引用正确性和故事人工评分; 团队确认数字、图表、限制与贡献归属后冻结最终报告和演示。

在此之前, mock、image-only、20 图融合对照和 64 图编码器实验继续只作为工程证据, 不会被换算成正式质量结论。

7 个人总结与贡献审计

我的主要贡献不是重写队友已有的 M3–M5, 而是把基线扩展成在无标注期可开发、在 8GB 本机可联调、出现生成式模型异常时可降级、标注到达后可切换到正式实验的系统。我完成了算法对照入口、M6/M7 生成式链路、M4 多后端、A7 第二编码器, 以及相应测试、故障定位与阶段文档。当前最重要的边界是: 工程链路基本具备, 正式质量结论仍须团队数据与人工评价。

表 4: 个人贡献审计

队友已有	本人新增	共同依赖/后续
M3–M5 三路索引、搜索服务、RRF 基线	无标注模式、任意目录入口、M5 weighted 对照	冻结的 M1 全量标注
候选检索和服务边界	M6 Top-20 listwise、校验与 8GB 测试	人工 query 与 qrels
项目 UI 与输出接口起点	M7 自动故事、SD 补图、AI 标识及页面联调	故事人工评价和最终演示
Chinese-CLIP 图像塔起点	M4 三后端; A7 Jina 适配、RoPE/NaN 修复	A5–A7 正式质量实验与团队报告

参考文献

- [1] Abubakar Abid, Ali Abdalla, Ali Abid, Dawood Khan, Abdulrahman Alfozan, and James Zou. Gradio: Hassle-free sharing and testing of machine learning models in the wild. arXiv preprint arXiv:1906.02569, 2019. URL <https://arxiv.org/abs/1906.02569>.
- [2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International*

- ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009. URL <https://dl.acm.org/doi/10.1145/1571941.1572114>.
- [3] DataArcTech. RagVL: Multimodal large language models are strong rerankers. GitHub repository, 2025. URL <https://github.com/DataArcTech/RagVL>.
- [4] Ting-Hao Huang, Francis Ferraro, Nasrin Mostafazadeh, Ishan Misra, Aishwarya Agrawal, Jacob Devlin, Ross Girshick, Xiaodong He, Pushmeet Kohli, Dhruv Batra, C. Lawrence Zitnick, Devi Parikh, Lucy Vanderwende, Michel Galley, and Margaret Mitchell. Visual storytelling. In *Proceedings of NAACL-HLT*, 2016. URL <https://aclanthology.org/N16-1147/>.
- [5] Jina AI. jina-clip-v2: Multilingual multimodal embeddings for text and images. *arXiv preprint arXiv:2412.08802*, 2024. URL <https://arxiv.org/abs/2412.08802>.
- [6] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019. URL <https://arxiv.org/abs/1702.08734>.
- [7] Qwen Team. Qwen3-VL: Vision-language models. GitHub repository, 2025. URL <https://github.com/QwenLM/Qwen3-VL>.
- [8] An Yang, Junshu Pan, Junyang Lin, Rui Men, Yichang Zhang, Jingren Zhou, and Chang Zhou. Chinese CLIP: Contrastive vision-language pretraining in chinese. In *arXiv preprint arXiv:2211.01335*, 2022. URL <https://arxiv.org/abs/2211.01335>.

A 提交与证据映射

提交	对应证据
222f232	队友提交的 M3–M5 多模态检索基线；仅作为本人开发起点。
4457459	补全无标注开发模式、image-only 和评测门禁。
9c5d54e	扩展路由、人工评测工具、M6 基准与 M7 UI 桥接。
33551fe	补全任意图片目录的一键流水线与录屏指南。
6550040	扩展 M5 归一化加权融合及 RRF 工程对照。
c4d329c	补全 M6 Top-20 listwise 重排、降级逻辑和 8GB 基准。
0c54bf8	扩展 M7 自动故事、缺口检测、补图和 AI 生成标识。
223f3e0	补全 M4 三后端、回退与结构化输出验证。
a8f3a05	扩展 A7 jina-clip-v2、修复 RoPE/NaN 并完成资源对比。