

视觉语言相册检索项目个人技术总结

张添翼

学号：U202315231

2026 年 8 月

摘要

本报告总结我在视觉语言相册检索课程项目中的个人工作。项目的开发起点是队友已经提交的 M3-M5 多路索引、检索服务与 RRF 融合基线；我没有把这些已有代码记为个人独立成果，而是在其上继续扩展无标注开发流程、M5 融合对照、M6 视觉重排、M7 故事与缺图补全、M4 查询理解后端以及 A7 图像编码器适配。全部本地联调在 RTX 4060 Laptop 8GB 环境下开展，重点考察功能契约、异常降级、显存与时延。队友生产的 Qwen3.5 canonical 标注已经完成只读验收，我在该交付上完成 adapter 迁移、Train 1993/Val 369 全量三路索引联调、M5→M6 接口和三个 M7 故事；另整理了 100 条已审核查询及五类均衡的 50 查询候选池。候选级相关性判断 (relevance judgments) 尚未冻结，因此本文只报告工程与单查询指标链路 smoke，不据来源图正例声明正式 Recall、MRR、mAP 或 nDCG 提升。

关键词：视觉语言模型；多模态检索；重排序；视觉故事；本地部署

贡献归属声明： Git 提交 222f232 中原始 M3-M5 多模态检索流水线归属队友。本报告所称“本人工作”仅指从 4457459 起对该基线所做的扩展、补全、联调、验证与修复。

1 项目背景与个人任务边界

项目目标是让用户用中文自然语言检索个人相册，并在召回结果上完成引用问答和图文故事。技术计划将主链路划分为：M3 建立图像、结构化文本和 BM25 索引；M4 将查询拆成语义文本与硬条件；M5 融合三路召回；M6 用视觉语言模型重排 Top-20；M7 输出带引用回答、排序故事及带“AI 生成”标识的补图。图像塔采用 Chinese-CLIP 或 jina-clip-v2，二者均把文本与图片映射到同一向量空间 [5, 8]；向量索引由 FAISS 支持 [6]。

系统中的模型承担不同职责。Chinese-CLIP 是默认的快速广召回编码器：它预先编码图片，查询时只需编码文本并做向量近邻搜索。Qwen3-VL-2B-Instruct 则是较慢但能生成文本的图像理解模型，用于候选重排、带引用问答、故事和文生图提示词 [7]。因此 CLIP 解决“从大量图片中快速找候选”，Qwen3-VL 解决“对少量候选进行深入理解”。

2 队友代码基线分析

队友在提交 222f232 中已经形成 M3-M5 基线：图片向量、结构化描述向量与关键词 BM25 三路索引分别返回候选，搜索服务再用 RRF 按名次合并结果。RRF 不要求三路原始分数处在同一尺度，适合异构召回 [2]。该结构提供了清楚的编码器、索引、融合与服务边界，使后续功能可以逐层

表 1: 模块、开发起点与个人任务边界

模块	队友已有/共同起点	本人扩展	当前结论边界
M3	队友已有三路索引框架	补全迁移、image-only 与一致性验证	Train 1993/Val 369 三路索引已验收
M4	检索服务接口	补全规则、本地 Qwen、兼容 API 三后端	三查询只验证接口契约
M5	队友已有 RRF 基线	加入 weighted、Top-20 接口和评测池	候选级 qrels 未冻结
M6	候选重排接口	补全 Top-20 listwise、校验和质量接口	单查询 smoke 不是最终结论
M7	检索结果与 UI 起点	扩展自动故事、缺图补全和 AI 标识	三故事已跑，质量待人工评分
A7	Chinese-CLIP 默认图像塔	适配 jina-clip-v2 并修复 NaN	64 图只做资源对比

替换并保留默认行为。我的工作以此为起点，重点补足无标注阶段的可运行入口、替代算法对照、生成式模型联调、异常防护和可复现实验，而不是重新声明已有流水线的所有权。

3 个人技术工作

3.1 无标注开发模式与任意目录流水线

问题：队友仍在生成 M1 结构化标注时，完整文本索引与正式评测不能启动；若所有开发都等待交付，接口和显存问题会集中到最后阶段。**本人工作：**我补全 mock、image-only、full 三种运行模式，并增加任意图片目录的一键清单生成、配置复制、图像建库和服务入口。没有标注时只运行图像检索，不伪造结构化字段；收到标注后可切换 full 模式。**验证：**隐藏目录与 image-only 流程经过自动化测试，阶段产物均放在 Git 忽略目录。**限制：**mock 只验证接口，image-only 只验证图像分支，两者均不能替代完整 M3 或检索质量实验。收到队友 Qwen3.5 canonical v1.3 后，我没有修改其原始标注，而是选择性迁移 adapter 与导入 CLI，并用 manifest 的 image ID、split、路径和 SHA-256 做只读对齐。当前已导入 Train 1993、Val 369 条记录，并在两个 split 上构建 image/text/BM25 三路索引；这项工作属于基线迁移、联调和验收，不把队友的标注生产或原始 M3-M5 实现记为本人工作。

3.2 M5：归一化加权融合对照

问题：原有 RRF 能规避分数量纲差异，但技术计划同时要求与归一化加权和对照。**本人工作：**我在不改变默认 RRF 的前提下，增加分支内 min-max 归一化和可配置权重；分支不可用时只在有效分支间重新归一化权重，并保留每路原始分数、名次和降级信息。**验证：**在 20 图、17 条有效结构化标注和 12 条查询上，两种融合均完成 Top-8 检索，候选重合率和位次变化可被脚本复现。**限制：**该对照没有人工 qrels，92.71% 重合率只描述两个算法输出的相似程度，不代表准确率。

3.3 M6: Top-20 Listwise 视觉重排

问题：逐图 pointwise 调用稳定，但 Top-20 需要 20 次模型推理；listwise 一次处理候选更快，却可能输出未知、重复或遗漏 ID。多模态大模型作为重排器已有相关探索 [3]。**本人工作：**我把候选缩放为 5 列 contact sheet，保留编号和 image ID，并实现输出白名单、编号映射、去重、遗漏项按原序补尾以及硬失败/部分降级分开计数。**验证：**阶段性 3 条 Top-20 查询在 8GB 显存上完成；后续 M5→M6 正式接口接收 12 查询、240 个唯一候选，listwise 总耗时 110.968 s、峰值约 4.10 GiB，硬失败为 0，但 8/12 出现重复或遗漏 ID 后的部分降级。**限制：**另有 q001 固定候选单查询 smoke 验证了 MRR/nDCG 计算链路；它只有来源图正例，不能说明 listwise 排序质量优于 pointwise，也不能替代 50 查询候选级 qrels。

3.4 M7: 自动故事与缺图补全

问题：技术计划要求把 3–8 张图片组织为故事，并对叙事缺口生成插图；生成内容必须与实拍图明确区分。视觉故事任务可参考 VIST 的图像序列叙事设定 [4]。**本人工作：**我扩展了按时间桶和场景相似度排序、跨时段/低相似跳变检测、Qwen 故事与提示词生成、Stable Diffusion 1.5 FP16 补图，以及 `source=generated`、`ai_generated=true` 双重标识。进入扩散模型前卸载 Qwen，生成失败时保留原故事并显示原因。交互页面基于 Gradio[1]。**验证：**从 12 查询 M6 输出中选择三组、每组 5 张图片完成真实故事；其中 q03 检测到一个转场缺口并生成 512×512 PNG，记录同时具有 `source=generated` 与 `ai_generated=true`。**限制：**SD 1.5 是适合本机联调的阶段模型，并非计划首选的 SDXL/FLUX；现有结果不代表故事连贯性或风格一致性得分。

3.5 M4: 三后端查询理解

问题：否定、数量和 OCR 查询不能只依赖向量相似度；同时，本地模型或免费 API 不可用时不能阻断检索。**本人工作：**我补全 rules、local Qwen 和 OpenAI-compatible 三后端。规则层先保护场景、时间、数量、OCR 和否定等硬条件；LLM 仅补充软字段与 `semantic_text`，失败则记录原因并回退规则。兼容 API 客户端实现环境变量取 Key、超时、重试和响应解析。**验证：**本地 Qwen 的否定、数量、OCR 三类查询均完成结构化输出；无 Key 时 API 后端明确记录错误并安全回退。**限制：**尚无外部服务 Key，故只完成协议测试而未声称真实免费 API 调用成功；3/3 也不是查询理解准确率。

3.6 A7: jina-clip-v2 适配与稳定性修复

问题：A7 要求对比两个图像编码器，但 jina-clip-v2 初次加载后图像向量全为 NaN，不能直接写入 FAISS。**本人工作：**我增加编码器配置切换、Matryoshka 维度截断与索引元数据，并用逐层钩子定位 NaN 首次出现于视觉塔第 0 层 RoPE。其非持久 `freqs_cos/freqs_sin` 未从 checkpoint 恢复，我按模型配置确定性重建 buffer，同时在输出端加入 NaN/Inf 硬校验。**验证：**修复后的 8 图冒烟和 64 图资源测试均产生有限向量与非空 Top-5；当前完整仓库回归为 248 passed。**限制：**两模型分数不在同一标尺；资源差异不能推出检索质量差异。

3.7 正式评测准备与防循环门禁

问题：只把每条查询的来源图片标成 2，会使所有系统都容易获得正例，却无法评价其余候选是相关、部分相关还是不相关；直接用检索分数生成标签又会形成循环论证。**本人工作：**我合并并复核两批查询，形成 100 条来源正例集合，类别分布为 simple/compositional/negative/count/OCR = 28/26/14/14/18；再从五类各选 10 条，汇集 CLIP-only、text-only、BM25-only、三路 RRF 和 weighted 的 Top-5，形成平均 10.8 个候选的 50 查询池。我补全候选级 0/1/2 审核页、零等级保留、qrels 冻结门禁、A5 五变体与 A6 固定候选质量接口。**当前边界：**100 条查询已经审核，但 50 查询候选池中非来源候选仍需逐图判断；正式结果文件不存在时，报告不生成 A5/A6 最终表。

4 本地实验与结果

所有数据均来自 RTX 4060 Laptop 8GB 本地阶段实验。表中“峰值显存”指 PyTorch 的 CUDA 最大分配量，而非整机 `nvidia-smi` 占用。

表 2: M6 在 3 条查询、每条 Top-20 上的热态资源对照

指标	Pointwise	Listwise
模型调用数	60	3
平均每查询延迟 (s)	44.377	9.143
峰值 CUDA 显存 (GiB)	4.039	4.092
硬失败率	0%	0%
部分降级	不适用	1/3

M6 数据说明 contact-sheet 方案能在 8GB 上运行，并减少本地调用次数与这组测试的耗时；它没有证明排序更相关。M4 中本地 Qwen 完成 3/3 条接口联调：首条冷启动 10.085 s，后两条热调用均值约 2.697 s。M5 小样共 12 查询，RRF 与 weighted 的平均 Top-8 重合率为 92.71%，共同结果平均位次变化 0.446；单次平均延迟分别为 10.58 ms 与 6.62 ms。样本和计时轮数有限，不能据此断言 weighted 总是更快。

在正式 A6 接口上，我对 q001 的同一 Top-20 候选做了一次 source-positive smoke。Pointwise 20 次调用耗时 37.800 s、峰值 4.04 GiB；listwise 1 次调用耗时 9.158 s、峰值 4.09 GiB，无失败或降级，实测加速 4.128 倍。表中质量值只由来源图 `val-2007` 一个正例计算，用于验证三种顺序的指标接线，不能推广到正式集合。

表 3: q001 固定 Top-20 的 source-positive 指标链路 smoke（非最终结果）

指标	M5 baseline	Pointwise	Listwise
MRR	0.500	1.000	0.500
nDCG@10	0.631	1.000	0.631
模型调用数	0	20	1
推理耗时 (s)	0	37.800	9.158

表 4: A7 在相同 64 张图片、512 维设置下的资源对照

指标	Chinese-CLIP	jina-clip-v2
冷启动建库 (s)	6.060	10.510
峰值 CUDA 显存 (GiB)	0.394	2.577
平均热查询 (ms)	2.251	47.701
输出维度	512	512

在本次 batch 设置下, Chinese-CLIP 的建库、显存与查询资源开销较低, 因此继续作为默认快速召回编码器; jina-clip-v2 保留为多语言和可截断表示的 A7 对照。此结论仅针对资源, 正式选择仍需在同一人工 qrels 上比较 Recall@K、MRR、mAP 与 nDCG@10。M7 的 Qwen3-VL-2B 故事链及 SD 1.5 FP16 缺图生成也在本机串行运行, 证明链路可执行, 未给出故事质量分数。

5 关键问题、修复与反思

1. **结构化输出不等于结构可靠**。Qwen 曾把数组输出成字符串, 还把 prompt 示例中的否定词写入查询。修复不是继续堆示例, 而是在入口做类型归一化、收紧 schema, 并让硬过滤只信任确定性规则。由此我认识到 LLM 输出必须被当作不可信外部输入。
2. **部分结果也要可审计**。Listwise 曾重复 2 个 ID、遗漏 3 个 ID。系统去重并补尾可以保持页面可用, 但必须标记 `degraded=true`, 否则会掩盖模型失约。
3. **数值正常性应在索引前阻断**。Jina 的 NaN 并非模型权重损坏, 而是低内存加载下非持久 EVA RoPE buffer 未初始化。逐层定位、确定性重建和输出端有限值校验共同构成修复; 只在最终检索结果上观察会更难定位。
4. **8GB 的关键是生命周期而非单个峰值**。我采用小 batch、缩略 contact sheet、FP16、attention/VAE slicing, 并按“检索编码器 → Qwen → Stable Diffusion”串行卸载加载, 避免多个模型同时常驻。该策略以时延换取本机可运行性。

这些问题也说明, 自动化测试通过与正式实验完成是两件事: 当前 248 项测试通过, 证明接口和回归状态, 却不能替代候选级人工相关性、数据覆盖和统计显著性。

6 标注到达后的完成项与剩余门禁

队友标注到达后, 我按只读边界完成了以下联调:

1. 验收 Qwen3.5 canonical 2362 条输入; 7 个 Train ID 缺失被如实保留, 不由程序合成, 也不回退到其他模型。
2. 导入 Train 1993、Val 369 条统一标注, 并构建两个 split 的 image/text/BM25 三路索引; manifest 保存记录数、维度、模型指纹、配置与标注哈希。
3. 冻结 M5 → M6 v1.0 接口, 验证 12 条查询、每条 20 个唯一候选; 完成 listwise 资源测试并显式披露 8/12 部分降级。
4. 完成三个 M7 故事与一个真实缺图生成, 验证故事顺序、失败保留和 AI provenance。
5. 审核 100 条五类查询, 生成 50 查询多系统候选池, 补全 A5/A6 正式结果代码。

当前剩余门禁只有候选级人工判断及其下游结果冻结：必须把候选池中每张非来源图片明确标为 0/1/2，要求 50 个 `graded_query_ids` 完整、保留零等级，再运行 A5 五变体和 A6 `baseline/pointwise/listwise`。随后才能把正式 MRR、mAP、nDCG、失败率和分类分析写入报告。第二审核者尚未实际签字时，也必须保留单审核者限制。

7 个人总结与贡献审计

我的主要贡献不是重写队友已有的 M3–M5，而是把基线扩展成在无标注期可开发、在 8GB 本机可联调、出现生成式模型异常时可降级、标注到达后可切换到正式实验的系统。我完成了选择性迁移、接口对照、M6/M7 生成式链路、M4 多后端、A7 第二编码器、正式评测工具、部署与 Demo 文档，以及相应测试和故障定位。当前最重要的边界是：全量链路已经具备，正式 A5/A6 质量结论仍须完成 50 查询候选级人工判断。

表 5: 个人贡献审计

队友已有	本人新增	共同依赖/后续
M3–M5 三路索引、搜索服务、RRF 基线	Qwen3.5 选择性迁移、全量索引验收、weighted 对照	M1 标注生产仍归属队友
候选检索和服务边界	M6 Top-20 listwise、接口校验、8GB 与指标接线	50 查询候选级 qrels
项目 UI 与输出接口起点	M7 三故事、SD 补图、AI 标识及页面联调	故事人工评价和最终录屏
Chinese-CLIP 图像塔起点	M4 三后端；A7 Jina；正式评测与部署	A5/A6 冻结表与团队报告

参考文献

- [1] Abubakar Abid, Ali Abdalla, Ali Abid, Dawood Khan, Abdulrahman Alfozan, and James Zou. Gradio: Hassle-free sharing and testing of machine learning models in the wild. arXiv preprint arXiv:1906.02569, 2019. URL <https://arxiv.org/abs/1906.02569>.
- [2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009. URL <https://dl.acm.org/doi/10.1145/1571941.1572114>.
- [3] DataArcTech. RagVL: Multimodal large language models are strong rerankers. GitHub repository, 2025. URL <https://github.com/DataArcTech/RagVL>.
- [4] Ting-Hao Huang, Francis Ferraro, Nasrin Mostafazadeh, Ishan Misra, Aishwarya Agrawal, Jacob Devlin, Ross Girshick, Xiaodong He, Pushmeet Kohli, Dhruv Batra, C. Lawrence Zitnick, Devi Parikh, Lucy Vanderwende, Michel Galley, and Margaret Mitchell. Visual storytelling. In *Proceedings of NAACL-HLT*, 2016. URL <https://aclanthology.org/N16-1147/>.

- [5] Jina AI. jina-clip-v2: Multilingual multimodal embeddings for text and images. *arXiv preprint arXiv:2412.08802*, 2024. URL <https://arxiv.org/abs/2412.08802>.
- [6] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019. URL <https://arxiv.org/abs/1702.08734>.
- [7] Qwen Team. Qwen3-VL: Vision-language models. GitHub repository, 2025. URL <https://github.com/QwenLM/Qwen3-VL>.
- [8] An Yang, Junshu Pan, Junyang Lin, Rui Men, Yichang Zhang, Jingren Zhou, and Chang Zhou. Chinese CLIP: Contrastive vision-language pretraining in chinese. In *arXiv preprint arXiv:2211.01335*, 2022. URL <https://arxiv.org/abs/2211.01335>.

A 提交与证据映射

提交	对应证据
222f232	队友提交的 M3–M5 多模态检索基线；仅作为本人开发起点。
4457459	补全无标注开发模式、image-only 和评测门禁。
9c5d54e	扩展路由、人工评测工具、M6 基准与 M7 UI 桥接。
33551fe	补全任意图片目录的一键流水线与录屏指南。
6550040	扩展 M5 归一化加权融合及 RRF 工程对照。
c4d329c	补全 M6 Top-20 listwise 重排、降级逻辑和 8GB 基准。
0c54bf8	扩展 M7 自动故事、缺口检测、补图和 AI 生成标识。
223f3e0	补全 M4 三后端、回退与结构化输出验证。
a8f3a05	扩展 A7 jina-clip-v2、修复 RoPE/NaN 并完成资源对比。
bfc2c1c	迁移队友 Qwen3.5 adapter 与只读导入 CLI，不声明标注生产归属。
fc4e7c6	补全 Train/Val 全量三路索引一致性和 manifest 验证。
e7f40da--557216b	规定并验证 M5→M6 接口，补全离线 listwise 与资源指标。
94250c1,82478ca, 9451b78	补全 canonical M7 桥接、三个故事和正式运行记录。
c64a958	修复正式 qrels 的零等级保留。
6deb435	整理两批已审核查询为正式 100 条集合。
7401f86	构建五类均衡、五个 A5 变体的 50 查询候选池。
d5422a1	补全候选级 0/1/2 图片审核页。
ded5d2a	补全 qrels 冻结与完整性门禁。
a784a5e	补全 A5 五变体正式输出与来源哈希。
6b2401a	补全 A6 固定候选质量接口并完成 q001 smoke。
c9873fb,260fb4c	补全可复现 GPU 部署和最终 Demo 手册。