

视觉语言相册检索项目

正式评测补充报告

张添翼

学号: U202315231

2026 年 8 月 17 日

摘要

本补充报告更新个人报告提交后完成的正式候选级相关性标注、A5 混合召回和 A6 视觉重排结果。候选级 qrels 已通过完整性校验；结果显示 weighted 三路融合在当前 qrels 上优于其他 A5 方法，而 VLM pointwise/listwise 重排没有超过 M5 baseline 的排序质量。listwise 的主要收益是减少模型调用并获得约 4.50 倍于 pointwise 的总时延加速。本文不将上述结果泛化到未公开测试集，并保留单审核者限制。

1 数据与贡献边界

候选级审核覆盖 50 条五类均衡查询和 540 个候选判断, 等级分布为 0=204、1=202、2=184, 标注者为张添翼, qrels 校验结果为 `valid=true`。100 条查询的原始来源图正例集合和 Qwen3.5 canonical 标注生产仍属于队友/团队共同前置工作；张添翼负责候选审核工具、qrels 冻结门禁、正式 A5/A6 运行、结果分析和报告补充，不将队友原始 M3-M5 基线写成个人成果。

2 A5 混合召回

表 1: A5 正式结果：总体为 100 条查询，graded nDCG@10 为 50 条候选池查询

方法	Recall@5	Recall@10	MRR	mAP	nDCG@10	graded nDCG@10
CLIP-only	0.720	0.783	0.858	0.704	0.784	0.795
text-only	0.721	0.774	0.840	0.677	0.762	0.729
BM25-only	0.633	0.691	0.816	0.623	0.711	0.614
RRF 三路	0.733	0.804	0.858	0.707	0.788	0.756
weighted 三路	0.754	0.842	0.870	0.744	0.820	0.817

在本次冻结 qrels 和固定配置下，weighted 三路融合在所有主要指标上优于 RRF；这只能作为当前验证集上的实验观察，不能直接推断未公开测试集结果。

3 A6 固定候选池重排

正式 A6 直接使用人工审核过的候选池，允许每条查询有 1–20 张候选，避免因去重后不足 20 张而丢弃 q016、q027、q038 和 q091 等查询。

表 2: A6 正式结果：50 条查询、540 个候选

方法	MRR	nDCG@10	失败数	部分降级	资源摘要
M5 baseline	1.000	0.953	–	–	固定候选原序
pointwise	0.987	0.923	2/540	–	2.395 s/候选, 4.06 GiB
listwise	0.982	0.903	0/50	13/50	5.744 s/查询, 4.10 GiB

pointwise 总耗时为 1293.217 秒，listwise 总耗时为 287.192 秒，listwise 相对 pointwise 加速 4.503 倍。pointwise 的两次失败均为模型没有输出合法 JSON；listwise 没有硬失败，但 13 条查询出现重复或遗漏 ID 后的部分降级。

4 结论与局限

本次正式实验不能支持“VLM 重排提升排序质量”的表述：在当前人工 qrels 上，M5 baseline 的 MRR 和 nDCG@10 反而高于 pointwise/listwise。更准确的结论是：listwise 将昂贵的逐图调用压缩为每查询一次，显著降低了总时延，但仍需改进 ID 输出约束和部分降级率。qrels 只有一名审核者，候选池来自五种召回方法的去重并集，且没有覆盖完整验证集的所有图片；这些限制应在课程报告中明确写出。

可复现证据

- artifacts/evaluation/formal/qrels_validation.json
- artifacts/evaluation/formal/a5/a5_formal_results.json
- artifacts/evaluation/formal/a6/formal_candidate_pool.json
- artifacts/evaluation/formal/a6/formal_candidate_pool_quality.json
- scripts/benchmark_formal_candidate_pool.py