

忆见 AskAlbum：面向真实场景相册的 结构化标注、混合检索与叙事 Agent

视觉与自然语言处理课程设计小组

2026 年 8 月

摘要

本文介绍忆见 AskAlbum，一个面向真实场景相册的可复现视觉语言检索系统。系统将课程要求组织为 M0–M7 八个模块：用场景路由选择提示词，以视觉语言模型产生结构化标注，以回译和检测器完成可验证性检查，建立图像、结构化文本和 BM25 三路索引，理解复杂中文查询，使用 RRF 或归一化加权融合召回，再由 Qwen3-VL 对 Top-20 候选进行 listwise 重排，最后生成带引用的回答、按时间和场景排序的视觉故事，并在故事缺口处显式插入带 AI 标识的生成图片。队友提供了 M0–M2 以及原始 M3–M5 基线和 Qwen3.5 canonical 标注；本文将这些作为团队共同起点，重点报告其上的接口迁移、后标注联调、M6/M7、M4 后端、A7 编码器适配、正式评测框架、部署和 Demo 复现工作。实验在 RTX 4060 Laptop 8GB 上完成。12 条 Top-20 listwise 运行共处理 240 个候选，峰值 CUDA 分配约 4.10 GiB，硬失败为 0；三个 M7 故事中一个成功生成缺图。候选级 0/1/2 相关性判断尚未冻结，故本文不虚构最终 Recall、MRR、mAP 或 nDCG 质量结论。**关键词：**视觉语言模型；中文图文检索；混合召回；listwise 重排；视觉故事；可复现部署

贡献归属声明：队友完成了 M0–M2、Qwen3.5 canonical 标注和原始 M3–M5 三路索引、搜索服务与 RRF 基线。本文不将上述内容写成个人成果；团队报告按模块和角色描述贡献。本人主要完成基线迁移与一致性验收、M5–M6 接口、M6 listwise、M7 故事与缺图补全、M4 后端、A7 适配、评测门禁、部署和最终 Demo 文档。

1 引言

真实相册检索同时包含“找图”和“理解图”两类问题。用户可能提出简单查询“长颈鹿进食”，也可能提出含组合属性、否定、计数或 OCR 的查询，例如“窗边一只表情严肃的猫”“没有人物的乡间田野”“桌上摆着七个烤生蚝”或“写有库仑定律的物理笔记”。单一 CLIP 相似度适合快速召回，但难以可靠表达数量、否定和文字约束；单次 VLM 生成又难以扫描数千张图片。因此，本项目采用快模型广召回、慢模型精排、结构化证据约束输出的分层方案。

课程方案还要求体现 prompt engineering、多 Agent 编排、无公开测试集条件下的评估和可部署性。我们的系统明确使用顺序流水线、并行 fan-out/fan-in 和路由分发三种编排：M0–M2 为顺序链，M5 的三路召回并行后融合，M0/M4 根据场景和查询类型路由到不同 prompt 或后端。最终交付不是固定测试结果，而是一条可对新目录复跑的流水线。

2 相关工作

Chinese-CLIP 将中文文本与图像映射到共享空间，适合作为中文相册的低成本初筛编码器 [8]；jina-clip-v2 提供多语图文嵌入和 Matryoshka 截断能力 [5]。FAISS 支持在当前数据规模上使用精确内积检索 [6]。RRF 不依赖不同检索分支分数的共同标尺，适合异构结果融合 [2]。已有工作也探索将多模态大模型用作检索重排器 [3]。视觉故事任务与 VIST 的序列叙事设定相关 [4]，Gradio 则为本项目提供轻量交互界面 [1]。Qwen3-VL 是本地 M6/M7 的图像理解模型 [7]。

3 系统设计

3.1 总体架构与数据流

系统离线阶段从任意图片目录开始，在线阶段接收中文查询：

```
raw images -> M0 route -> M1 structured VLM annotation -> M2 validation
               -> M3 image/text/BM25 indexes
query -> M4 query understanding -> M5 parallel recall + fusion
               -> M6 Qwen3-VL rerank -> M7 answer/story/gap filling
```

M1 的核心输出不是一段自由 caption，而是可检验 schema，包括 scene、capture、objects、persons、OCR、relations、事件、情绪、双语关键词、不确定字段和置信度。这样一方面让文本检索可利用对象、关系和 OCR，另一方面为 M2 的对象级幻觉检查及 M7 的事实边界提供字段级证据。

3.2 M0–M2：路由、标注与验证

M0 在计算图像索引向量时复用 CLIP 图像塔，对室内、街景、自然、人像、美食、夜景、文字场景等类别做 zero-shot 路由，并为 M1 选择类别专用 prompt。M1 使用 JSON Schema 约束、先证据后结论的字段顺序、负面约束、少样本锚定、自洽采样和跨模型交叉检查。M2 以 GroundingDINO/OWLv2 类检测器核对 objects，以 OCR 核对文字字段，并保留 uncertain_fields；可选的 EchoBack 将描述输入文生图模型，再用 DINOv2 比较重建图和原图，作为无参考自验证信号。M0–M2 及 canonical 标注由队友完成，本文只记录其接口和验收边界。

3.3 M3：三路索引

M3 为每个 split 建立三个相互独立的分支：Chinese-CLIP 图像向量索引、结构化标注文本的稠密向量索引和关键词 BM25 倒排索引。所有索引都以 manifest 中的 image_id、split、相对路径和 SHA-256 绑定，防止图片、标注和候选 ID 错配。当前全量验收为 Train 1993 条、Val 369 条，三路索引均能从同一 manifest 重建。该数据迁移和一致性验收是本人在队友基线上的工作，不等同于重新实现队友的原始索引。

3.4 M4：查询理解与回退

M4 将查询解析为 category、semantic_text、entities、attributes、negative、count、OCR 和 time 等槽位。rules 后端直接识别中文否定词、数字、引号文本和时间词；local Qwen 后端补充软语

义；OpenAI-compatible 后端可接入免费或自托管 API。LLM 后端失败、超时、无 Key 或输出非法 JSON 时，系统保留规则解析并记录 `fallback_reason`，而不是阻断 M5。该设计对负面、计数和 OCR 查询尤其重要。

3.5 M5：并行召回与融合

三路召回并行执行并保留 `branch_scores`、`branch_ranks` 和降级信息。默认 RRF 计算为

$$\text{RRF}(d) = \sum_{b \in B} \frac{1}{k + \text{rank}_b(d)},$$

其中 k 为平滑常数。为满足消融要求，另实现分支内 min-max 归一化后的加权融合，默认权重为 `image/text/BM25 = 0.4/0.4/0.2`；分支失效时仅在有效分支间重新归一化。两种方法在 20 图冒烟中 Top-8 平均重合率为 92.71%，共同候选平均位次变化为 0.446；RRF 和 weighted 平均耗时分别为 10.58 ms 和 6.62 ms。该小样本只证明工程可运行，不代表质量优劣。

3.6 M5–M6 契约与 M6 listwise

M5 输出采用 `m5-to-m6-v1.0` 契约：每个 query 一行、恰好 20 个唯一候选、rank 为 1–20、分支分数和名次键集合一致，并通过 `manifest`、`路径`、`split` 和图像解码完整扫描。M6 将 Top-20 编号拼成 `contact sheet`，调用 `Qwen3-VL-2B-Instruct` 一次输出候选 ID 顺序。白名单校验会去重重复 ID、按 M5 原序补回遗漏 ID；未知 ID、空输出、非法 JSON 或异常触发完整 M5 硬回退，部分修复写入 `degraded` 和 `mismatch`。

表 1: M6 正式 listwise 资源与稳定性结果

指标	实测值
查询数 / 候选数	12 / 240
接口校验	<code>valid=true</code> ，错误 0
总耗时 / 平均每查询	110.968 s / 9.247 s
峰值 CUDA 分配	4,405,989,376 B (约 4.10 GiB)
无降级 / 部分降级 / 硬失败	4/12 / 8/12 / 0/12

8 条部分降级均来自模型返回重复或遗漏候选 ID，系统按契约修复且没有未知 ID 或异常导致的整批回退。`q001` 的固定候选 `smoke` 另验证了 `pointwise`、`listwise`、`MRR/nDCG` 计算链路，但 `qrels` 只有来源图正例，不能作为最终质量结论。

3.7 M7：引用回答、视觉故事与缺图补全

M7 严格读取 M6 的 `query` 和 `ordered IDs`，再从 `canonical` 映射中取 `summary`、`scene`、时间桶、实体、OCR 和不确定性。自动排序优先使用时间桶，并以场景/实体相似度做稳定 `tie-break`；故事输入限定为 3–8 张图，`sections` 顺序必须与 `ordered IDs` 一致。转场相似度过低或时间跨度过大时插入 `missing gap`。只有用户显式启用补图才加载 `Stable Diffusion`；生成段落固定写入 `source=generated` 和 `ai_generated=true`，避免将合成图误当真实检索结果。

表 2: M7 三个正式故事的工程验收

故事	图片数	gap	结果
m6-q01	5	2	保留 missing 占位, 未请求生成
m6-q03	5	1	成功生成 1 张, 双重 AI 标识
m6-q09	5	2	保留 missing 占位, 未请求生成

4 实验设置

硬件为 RTX 4060 Laptop 8GB; 环境由 pixi/Conda 锁定, 默认本地模型为 Qwen3-VL-2B-Instruct 和 Chinese-CLIP, 生成补图使用轻量 Stable Diffusion 配置。训练集和验证集分别为 1993 和 369 张已映射图片。离线索引、在线 Gradio 服务、M6/M7 CLI 和 Docker Compose 均提供复现入口。

4.1 评测设计与防循环门禁

验证集查询先由来源图 ID 审核, 形成 100 条查询, 类别为 simple 28、compositional 26、negative 14、count 14、OCR 18。再从五类各选 10 条, 收集五种召回变体的 Top-5, 构成 50 查询候选池, 平均每条 10.8 个候选。候选级人工标签采用 0/1/2: 不相关、部分相关、核心相关。标签不能由检索分数自动推断; 来源图正例也不能替代对其他候选的判断。冻结后统一运行 A5 五变体和 A6 baseline/pointwise/listwise, 报告 Recall@K、MRR、mAP 和 nDCG@10, 并按查询类别分组。截至本文提交, candidate_relevance.csv、qrels_validation.json、正式 A5 和 A6 质量文件尚未产生, 因此正文不填写最终排序质量数字。这一门禁保证评测不使用模型自身分数制造标签。

4.2 A7 编码器资源对比

在同一 Val 前 64 张图片、512 维和五条中文查询上, 两个编码器只做资源实验。

表 3: A7: Chinese-CLIP 与 jina-clip-v2 资源对比

指标	Chinese-CLIP 512	jina-clip-v2 512
模型大小	1.507 GB	1.748 GB
batch size	4	1
冷启动建库	6.060 s	10.510 s
吞吐	10.560 image/s	6.089 image/s
峰值 CUDA	0.394 GiB	2.577 GiB
索引大小	132,669 B	132,709 B
热查询均值	2.251 ms	47.701 ms

两者都能在 8GB 显存上运行; 本次实验只说明资源可行性, 不能说明哪一个在本数据集上的 Recall 更高。jina 的多语能力、512×512 输入和 Matryoshka 截断是适配价值, 但不同编码器索引不

可混用，切换后必须重建 image 分支。

5 结果、讨论与局限

本项目已经得到一条从目录到 Demo 的完整工程路径：队友 canonical 标注经过只读映射后，Train/Val 三路索引可以重建；M4 在模型不可用时安全回退；M5 输出可审计的 Top-20；M6 在 8GB 显存上完成 listwise 运行且硬失败为 0；M7 能产生有序故事并标识生成图；Docker 和最终 Demo runbook 提供部署复现。工程结果表明，8GB 设备不需要加载 7B 级 VLM 才能完成全流程，关键是把昂贵模型限制在 Top-20 和故事 gap 上。主要局限有三点。第一，8 条 M6 部分降级显示 listwise 提示词和输出解析仍需改进，后续可使用严格 JSON grammar、短 ID token 和二次校验降低遗漏。第二，候选级 qrels 尚未冻结，当前不能回答“RRF、weighted、pointwise、listwise 谁的质量更好”；这不是遗漏结果，而是主动避免循环评测。第三，M7 的故事连贯性和生成图真实性尚未进行人工 Arena、CLIPScore 或 CHAIR 评价，当前结论限于流程、资源和可追溯性。迁移到抽象艺术、古典绘画或医学影像时，所谓迁移能力主要指同一套图文编码、结构化 schema、查询理解和重排流程在域外图像上的检索与描述性能保持程度，而不是模型是否见过该领域。预计 OCR、风格词和医学术语会造成分布偏移；应增加少量领域查询与人工 qrels，比较零样本性能、提示词增强性能和错误类型，并报告置信度与幻觉率。

6 结论

忆见 AskAlbum 将结构化标注、可验证性、混合检索、VLM 重排和视觉叙事整合为一条可复现流水线。团队边界清晰：队友交付 M0–M5 基础和 canonical 标注，本文完成其上的工程联调、M6/M7、评测门禁、A7、部署与 Demo。当前最重要的剩余步骤是完成 50 条候选池的 0/1/2 人工判断，冻结 qrels 后运行 A5/A6 正式质量实验，并将结果补入团队报告；在此之前，本文只报告可验证的工程和资源证据。

贡献声明

为避免将队友工作误记为个人成果，贡献按角色划分：标注与 M0–M2 由标注/前置模块角色完成；原始 M3–M5 三路检索基线由检索基线角色完成；本人负责基线迁移验收、M5 融合对照、M5–M6 接口、M6 listwise、M7 故事和补图、M4 后端、A7 适配、正式评测脚本、Docker 部署与最终 Demo 文档。所有最终质量指标须以冻结的人工 qrels 为准。

A 接口与复现命令

M5–M6 的最小契约如下：每行一个 query；query_id 唯一；candidates 长度为 20；每个候选包含唯一 image_id、rank、path、branch_scores 和 branch_ranks；候选路径、split 和图像 SHA-256 必须与 index manifest 一致。M6 输出保留 M5 字段，并增加 rerank_rank、degraded 和 mismatch。M7 生成段落必须同时带 source=generated 与 ai_generated=true。典型复现命令：

```
conda run -n vlm-course python run.py --input_dir ../Val --dry-run --launch
```

```
conda run -n vlm-course python scripts/validate_m5_m6_interface.py \\  
  --input artifacts/evaluation/m5_to_m6_candidates.jsonl \\  
  --report artifacts/evaluation/m6_validation_report.json  
conda run -n vlm-course python scripts/run_m6_from_m5.py \\  
  --input artifacts/evaluation/m5_to_m6_candidates.jsonl \\  
  --method listwise --output artifacts/evaluation/m6_rerank_results.jsonl  
conda run -n vlm-course python scripts/run_m7_from_m6.py \\  
  --m6-results artifacts/evaluation/m6_rerank_results.jsonl \\  
  --query-id m6-q03 --select-count 5 \\  
  --output artifacts/evaluation/m7_stories/m6-q03.json
```

参考文献

- [1] Abubakar Abid, Ali Abdalla, Ali Abid, Dawood Khan, Abdulrahman Alfozan, and James Zou. Gradio: Hassle-free sharing and testing of machine learning models in the wild. *arXiv preprint arXiv:1906.02569*, 2019. URL <https://arxiv.org/abs/1906.02569>.
- [2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of SIGIR*, pages 758–759, 2009. URL <https://dl.acm.org/doi/10.1145/1571941.1572114>.
- [3] DataArcTech. RagVL: Multimodal large language models are strong rerankers. GitHub repository, 2025. URL <https://github.com/DataArcTech/RagVL>.
- [4] Ting-Hao Huang, Francis Ferraro, Nasrin Mostafazadeh, Ishan Misra, Aishwarya Agrawal, Jacob Devlin, Ross Girshick, Xiaodong He, Pushmeet Kohli, Dhruv Batra, C. Lawrence Zitnick, Devi Parikh, Lucy Vanderwende, Michel Galley, and Margaret Mitchell. Visual storytelling. In *Proceedings of NAACL-HLT*, 2016. URL <https://aclanthology.org/N16-1147/>.
- [5] Jina AI. jina-clip-v2: Multilingual multimodal embeddings for text and images. *arXiv preprint arXiv:2412.08802*, 2024. URL <https://arxiv.org/abs/2412.08802>.
- [6] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3):535–547, 2019. URL <https://arxiv.org/abs/1702.08734>.
- [7] Qwen Team. Qwen3-VL: Vision-language models. GitHub repository, 2025. URL <https://github.com/QwenLM/Qwen3-VL>.
- [8] An Yang, Junshu Pan, Junyang Lin, Rui Men, Yichang Zhang, Jingren Zhou, and Chang Zhou. Chinese CLIP: Contrastive vision-language pretraining in chinese. In *arXiv preprint arXiv:2211.01335*, 2022. URL <https://arxiv.org/abs/2211.01335>.